



MYVOICE: Reconocimiento de comandos simples en dispositivos de voz asistida mediante señales EMG

1. Introducción

La laringectomía total implica la pérdida de la voz natural, lo que afecta profundamente la comunicación y la calidad de vida de los pacientes. Como alternativa, la laringe electrónica ofrece una solución al permitir la articulación del habla mediante vibraciones mecánicas transmitidas a través del cuello [1]. Sin embargo, la voz obtenida a través de la laringe electrónica presenta importantes limitaciones, tales como un tono monótono, la presencia de ruido mecánico y una falta de naturalidad [2]. Estas características no solo afectan la percepción de la voz, sino que también dificultan la correcta diferenciación de palabras en situaciones cotidianas [3].

La señal de EMG de los músculos cervicales ha demostrado ser eficaz para diagnosticar afecciones médicas como la disfagia, estimando la actividad muscular del cuello y midiendo vibraciones de las cuerdas vocales [1]. En los últimos años, se ha comenzado a utilizar esta técnica para la traducción del habla en personas con condiciones como la disfonía y frente a las consecuencias de procedimientos como las laringectomías [2]. Sin embargo, la difícil obtención de una señal clara debido a su baja variabilidad y contaminación con ruido de movimientos corporales sigue siendo un obstáculo significativo para la discriminación precisa de comandos simples como "sí" y "no" [3].

En este contexto, el procesamiento digital de señales emerge como una herramienta clave para analizar y optimizar la interpretación de la actividad bioeléctrica muscular [4]. El principal desafío radica en extraer características robustas y confiables de las señales EMG, como son la frecuencia de activación, la amplitud y la duración de la contracción, para garantizar una clasificación precisa de los comandos.

Ante esto, surge la siguiente pregunta de investigación:

¿De qué manera el procesamiento de la señal EMG puede optimizar la discriminación de comandos simples a partir de la activación muscular del cuello?

2. Objetivo General

Diseñar y desarrollar un sistema de control intuitivo y manos libres para una laringe electrónica, mediante la captura y el procesamiento de señales electromiográficas (EMG) de la musculatura cervical, con el fin de clasificar sílabas y palabras específicas que permitan al paciente recuperar una comunicación verbal más fluida y natural.

3. Alcance



El alcance de este proyecto contempla el diseño, desarrollo y validación de un software prototipo en etapa inicial, orientado a la discriminación de comandos específicos a partir de señales electromiográficas (EMG) de la musculatura cervical.

Respecto a los elementos incluidos en el proyecto, se abarca en primer lugar la adquisición de datos basada en la captura y almacenamiento de los registros de EMG correspondientes a la ejecución motora de los monosílabos a evaluar. Asimismo, el proyecto comprende la etapa de procesamiento y clasificación con un algoritmo de IA entrenado con los datos extraídos y concluye con el desarrollo de una interfaz de usuario que permite cargar archivos de señales EMG para predecir automáticamente el monosílabo ejecutado.

4. Metodología

La metodología implementada en este proyecto se dividió en cuatro fases fundamentales que comprenden la adquisición de señales biológicas, el procesamiento de los datos, el desarrollo del modelo de inteligencia artificial y, finalmente, el despliegue de la solución en una plataforma web.

En la primera fase, se realizó la adquisición de señales de electromiografía de superficie (sEMG) utilizando el sistema de desarrollo MuscleBIT, basado en la plataforma BITalino, en conjunto con el software de registro OpenSignals. Para la captura de la actividad muscular, se diseñó una configuración de cinco canales orientada a la región del cuello y la mandíbula. El canal 1 se asignó como referencia a tierra (GND) y se ubicó en la clavícula izquierda. Los canales 2 y 3 se destinaron al registro del músculo estilohioideo derecho e izquierdo, respectivamente. Por último, los canales 4 y 5 se posicionaron para medir la actividad del vientre anterior del músculo digástrico en sus lados derecho e izquierdo. Los registros resultantes de las sesiones de pruebas fueron exportados inicialmente desde el software en formatos nativos .h5 y .txt. Con el fin de estandarizar y facilitar la manipulación de la información, se desarrollaron scripts personalizados en Python para ejecutar un proceso de extracción, transformación y carga, convirtiendo la totalidad de los datos al formato estructurado .json.

En la segunda fase, los archivos .json fueron importados en la plataforma Edge Impulse para su procesamiento y preparación. Con el objetivo de segmentar las señales continuas, se aplicó una técnica de ventaneo (windowing) temporal sobre los flujos de datos. A partir de estas ventanas, se implementó un bloque de procesamiento especializado en la extracción de características, extrayendo componentes tanto en el dominio del tiempo como en el dominio de la frecuencia. Este procedimiento permitió aislar las firmas electromiográficas más relevantes de cada movimiento o estado, reduciendo de manera óptima el ruido inherente a la señal y la dimensionalidad de las variables antes de ingresar a la etapa de aprendizaje automático.

La tercera fase consistió en el diseño, entrenamiento y validación de una arquitectura de Red Neuronal Densa (DNN) dentro del entorno de Edge Impulse, configurada para resolver un problema de clasificación multiclase que abarcó los estados Basal, No, Sí y un estado de Incertidumbre (Uncertain). Tras culminar el proceso de entrenamiento, el modelo fue optimizado mediante una cuantización de tipo entero de 8 bits (int8) para reducir el uso de



memoria y asegurar la viabilidad del modelo en sistemas computacionales ligeros.. El modelo cuantizado final demostró una alta capacidad de generalización al registrar una exactitud (accuracy) global del 90.54% y un área bajo la curva ROC (AUC) de 0.99. Asimismo, las métricas ponderadas de precisión y sensibilidad (recall) se situaron en un 0.93, respaldadas por un F1-score general de 0.92, el cual mostró desempeños individuales por clase de 0.99 para el estado Basal, 0.90 para el estado No y 0.87 para el estado Sí.

Finalmente, la cuarta fase se centró en el despliegue tecnológico del sistema de clasificación. Tras validar las métricas de rendimiento de la red neuronal, se procedió con la exportación (deployment) del modelo desde Edge Impulse en forma de una librería optimizada en lenguaje C++. Para permitir su ejecución en entornos basados en la web, el motor de inferencia en C++ se integró al ecosistema de desarrollo de Python. La lógica del clasificador y el backend del sistema se implementaron y subieron a la plataforma Streamlit, donde se gestionaron las credenciales de acceso y seguridad correspondientes, culminando con la puesta en producción y la publicación de la interfaz web oficial para el monitoreo y visualización del proyecto.

5. Funcionalidades

El sistema web desarrollado en Streamlit se estructuró como una plataforma interactiva y de alto rendimiento para el análisis de electromiografía de superficie (sEMG) enfocada en el reconocimiento de habla silenciosa. La interfaz fue diseñada bajo un enfoque modular que traduce el procesamiento de señales complejas y la ejecución de modelos de inteligencia artificial en herramientas visuales y analíticas intuitivas, distribuyéndose en cuatro componentes funcionales principales.

La primera funcionalidad del sistema corresponde a la gestión de conectividad, diagnóstico de hardware y soporte teórico. Mediante un módulo dinámico en la interfaz, la aplicación monitorea en tiempo real el estado de sincronización con el dispositivo de adquisición BITalino (r)evolution. En caso de detectar una desconexión física o inalámbrica, la plataforma despliega alertas en la barra lateral e instruye al operador sobre los pasos de restablecimiento. De manera complementaria, este bloque integra un glosario técnico y un panel educativo colapsable que detalla los principios fisiológicos de los músculos suprahioides instrumentalizados (estilohioides y digástricos anteriores), proporcionando al usuario los perfiles espectrales de frecuencia y los rangos típicos de amplitud esperados para cada estado evaluado.

La segunda funcionalidad abarca el entorno de simulación y la visualización gráfica de señales en tiempo real. La plataforma incorpora un generador de escenarios clínicos que permite simular la captura de datos de cuatro perfiles de pacientes con condiciones bioeléctricas diferenciadas. Esta herramienta permite evaluar de manera inmediata la robustez del modelo ante una señal estable y limpia (Persona A), una señal ruidosa por contacto electroquímico subóptimo (Persona B), una señal afectada por deriva lenta de la línea base debido al movimiento de los cables (Persona C), o bien, una señal con amplitud reducida a causa de fatiga muscular progresiva (Persona D). Al activar la generación, la interfaz despliega gráficos interactivos de la amplitud frente al tiempo para los cuatro canales analógicos, calculando de forma instantánea el valor de la raíz media cuadrada



(RMS) para cada uno, facilitando la inspección rápida de los patrones antes de proceder con el análisis predictivo.

La tercera funcionalidad, que representa una de las mayores capacidades analíticas de la plataforma, consiste en el módulo de carga y procesamiento por lotes de datos reales en formatos estructurados (.txt o .csv) provenientes directamente del software OpenSignals de BITalino. A través de un componente de carga de archivos (*file uploader*), el usuario puede importar registros históricos de sesiones de prueba. El sistema valida automáticamente la integridad del archivo cargado, identificando el número total de muestras y la correspondencia de los cuatro canales musculares. Una vez validada la información, el *backend* segmenta la señal continua en ventanas temporales secuenciales; por ejemplo, ante un registro de 5000 muestras, realiza una partición automática que genera múltiples ventanas de clasificación independientes. Los resultados de este análisis por lotes se tabulan dinámicamente en una matriz detallada que expone, para cada ventana numerada, la predicción categórica final, el porcentaje global de confianza y el desglose probabilístico exacto en formato decimal para las tres clases del modelo (Basal, No y Sí).

Finalmente, la cuarta funcionalidad está orientada al análisis estadístico acumulado y la validación visual de los resultados. Para complementar el procesamiento de datos reales o simulados, la interfaz genera un histograma dinámico titulado "Distribución de predicciones por ventana", el cual contabiliza y grafica la frecuencia con la que el modelo asigna cada clase a lo largo del archivo analizado, permitiendo correlacionar visualmente la densidad de los intentos de habla frente a los periodos de reposo. Asimismo, el sistema mantiene un panel de control perimetral en el extremo izquierdo que registra el conteo histórico total de predicciones validadas bajo un filtro de post-procesamiento con un umbral de confianza mínimo configurable, ofreciendo al operador una herramienta robusta para auditorías de datos, almacenamiento de bitácoras y exportación de reportes de desempeño clínico.



6. Interfaz de Usuario




Figura 1. Diagrama de flujo de uso



7. Tecnologías Utilizadas

Hardware y Captura de Datos

MuscleBIT (BITalino): Kit de desarrollo y plataforma de hardware biomédico utilizado para la adquisición de las señales electromiográficas (EMG) de la musculatura cervical mediante sensores de superficie.

OpenSignals: Software especializado de la suite BITalino, empleado para la visualización en tiempo real, registro y almacenamiento de los datos bioeléctricos crudos provenientes del hardware.

Procesamiento, Entrenamiento e Inteligencia Artificial

Python: Lenguaje de programación principal utilizado para la manipulación de datos, integración de scripts y desarrollo de la lógica del sistema.

Edge Impulse: Plataforma de desarrollo para *Edge AI* utilizada en la etapa de ingeniería de características (procesamiento digital de señales en tiempo y frecuencia) y para el entrenamiento del modelo de aprendizaje profundo.

Red Neuronal Densa (DNN - *Dense Neural Network*): Arquitectura de Inteligencia Artificial seleccionada para la clasificación de los monosílabos, entrenada para reconocer los patrones de activación muscular a partir de los descriptores extraídos.

Interfaz de Usuario y Despliegue

Streamlit: Framework de código abierto basado en Python, utilizado para el diseño y construcción rápida de la interfaz gráfica de usuario (UI), permitiendo la carga de archivos de señales y la visualización de predicciones.

Streamlit Cloud: Plataforma de alojamiento (hosting) basada en la nube empleada para el despliegue público del software prototipo, facilitando su acceso y prueba desde cualquier navegador web.

8. Limitaciones

El sistema presenta limitaciones técnicas asociadas principalmente al hardware de adquisición y su entorno de aplicación. El dispositivo MuscleBIT (plataforma BITalino) es una herramienta diseñada para el prototipado rápido y la investigación, por lo que carece de certificación de grado médico. Esta condición técnica incrementa la susceptibilidad a ruidos ambientales y artefactos por movimiento de los cables durante las pruebas. En consecuencia, la plataforma creada debe ser considerada estrictamente como una herramienta tecnológica de apoyo experimental o asistencia comunicativa preliminar, y de ninguna manera como un sistema de diagnóstico autónomo o definitivo.



Por otra parte, existe una limitación metodológica crítica respecto a la representatividad de los datos y la validación en escenarios reales. El modelo de inteligencia artificial se desarrolló utilizando señales de sujetos sanos y perfiles simulados, evidenciando una escasez de datos provenientes de pacientes reales sometidos a laringectomías. Debido a que una laringectomía altera drásticamente la anatomía y la dinámica de activación de la musculatura suprahióidea, el algoritmo podría experimentar una degradación en su precisión ante dichos usuarios. Asimismo, al no contar con ensayos clínicos ni validación supervisada por especialistas, la eficacia del sistema queda sujeta a variables externas no controladas, como la fatiga muscular o la colocación subóptima de los electrodos superficiales.



FOTOS

Vista General

Señales EMG

Pipeline de Inferencia

Acerca del Proyecto

Acerca del Proyecto EMG + IA

Ficha técnica

Parámetro	Valor
Dispositivo	BITalino (r)evolution
Frecuencia de muestreo	1000 Hz
Canales	4 (A1-A4)
Ventana	1000 muestras (1 s)
Features	148 (FFT 64 pts, 4 canales)
Modelo	FC 148→10→30→120→3
Engine	TFLite + EON Compiler
Quantización	int8
Tensor Arena	3539 bytes
Umbral de confianza mínimo	85%
Plataforma	Edge Impulse (Studio #1042231)

Clases

Clase	Descripción	Perfil espectral
BASAL	Reposo, sin intento de habla	Ruido de fondo ~0.1 mV
NO	Intento de articular "NO"	Burst ~30–80 Hz
SI	Intento de articular "Sí"	Burst ~80–200 Hz

Referencias

- Edge Impulse Studio: [#1042231](#)
- SDK: Edge Impulse Inferencing SDK
- BITalino: <https://bitalino.com>

Estadísticas

Predicciones totales

1

BASAL

1

NO

0

SI

0

Limpiar historial

Proyecto EMG — Reconocimiento de palabras

v2.0 — 05/07/2026

Vista General

Señales EMG

Pipeline de Inferencia

Acerca del Proyecto

Pipeline completo: señal → features → clasificación

Palabra a simular

NO

Ejecutar inferencia

Clasificar ahora

✓ Clasificación completada — NO con 91.9% de confianza

NO

Confianza

91.86%

Distribución de probabilidades

100

50

0

Probabilidad (%)

4.1

91.9

4.1

BASAL

NO

SI

Clase

CH1 — RMS (mV)

0.156

CH2 — RMS (mV)

0.153

CH3 — RMS (mV)

0.154

CH4 — RMS (mV)

0.157

Interpretación de la señal EMG

- Línea base plana (~0 mV): reposo muscular (BASAL)
- Bursts de actividad: contracción muscular al articular "NO" o "SI"
- Amplitud típica: 0.1–5 mV (depende del músculo, electrodos, y fatiga)
- Frecuencia: el espectro EMG útil está entre 20–450 Hz
- Persona A (señal estable) muestra patrones limpios; Persona D (fatiga) tiene amplitud reducida y espectro desplazado



Datos reales (BITalino TXT)

Sube un archivo TXT/CSV de BITalino (4 canales, ≥1000 muestras)



PROYECT...in_005.txt
210.0KB



✓ 5000 muestras, 4 canales

✓ 9 ventanas clasificadas

Ventana	Predicción	Confianza (%)	BASAL	NO	SI
1	BASAL	100.0	1.000	0.000	0.000
2	BASAL	100.0	1.000	0.000	0.000
3	BASAL	100.0	1.000	0.000	0.000
4	BASAL	100.0	1.000	0.000	0.000
5	BASAL	100.0	1.000	0.000	0.000
6	BASAL	100.0	1.000	0.000	0.000
7	BASAL	100.0	1.000	0.000	0.000
8	BASAL	100.0	1.000	0.000	0.000

4	BASAL	100.0	1.000	0.000	0.000
5	BASAL	100.0	1.000	0.000	0.000
6	BASAL	100.0	1.000	0.000	0.000
7	BASAL	100.0	1.000	0.000	0.000
8	BASAL	100.0	1.000	0.000	0.000
9	BASAL	100.0	1.000	0.000	0.000

Distribución de predicciones por ventana





Visualización de señales EMG en tiempo real

Clase a simular

☒ BASAL ☐ NO ☐ SI

Ventanas a generar

3

▶ Generar señales

Señal EMG — BASAL — Persona A — Señal estable



Estado del dispositivo

BITalino desconectado. Conecta desde la barra lateral.

¿Qué mide la EMG?

La electromiografía (EMG) mide la actividad eléctrica generada por las fibras musculares durante la contracción. En el habla silenciosa, los músculos suprahioides se activan sutilmente al *intentar* articular una palabra, incluso sin emitir sonido.

- BASAL: reposo, solo ruido de fondo muscular
- NO: activación media, patrón espectral ~30–80 Hz
- SI: activación fuerte, patrón espectral ~80–200 Hz

Clasificación de palabras mediante señales EMG

Ingeniería Biomédica — BITalino + Edge Impulse + TFLite Micro

Sistema de reconocimiento de habla silenciosa

Este sistema clasifica intentos de pronunciación de palabras ("SI", "NO", "BASAL") a partir de señales electromiográficas (EMG) de superficie en 4 músculos suprahioides involucrados en la articulación del habla.

Pipeline

1. **Adquisición** — BITalino a 1000 Hz, 4 canales
2. **Preprocesamiento** — Ventaneo de 1000 muestras (1 s)
3. **DSP** — FFT espectral de 64 puntos → 148 features
4. **Normalización** — StandardScaler (148 medias, 148 escalas)
5. **Inferencia** — Red Fully-Connected cuantizada int8 (148→10→30→120→3)
6. **Post-procesamiento** — Softmax + umbral de confianza ≥ 60%

Canales musculares

- Músculos suprahioides:
 - Estilohioideo D/I
 - Digástrico anterior D/I
 - Hioidioideo
 - Genihioideo

Canal	Músculo
A1	Estilohioideo derecho
A2	Estilohioideo izquierdo
A3	Digástrico anterior derecho
A4	Digástrico anterior izquierdo



9. Referencias

- [1] J. T. Heaton et al., "Development of a Wireless Electromyographically Controlled Electrolarynx Voice Prosthesis," 2022.
- [2] R. B. Siqueira et al., "Laryngeal electromyography in dysphonic patients with incomplete glottic closure," *Int. Arch. Otorhinolaryngol.*, 2022.
- [3] J. Wu. et al., "A novel silent speech recognition approach based on parallel inception CNN using surface electromyography," *Frontiers in Neurorobotics*, vol. 16, 2022.
- [4] P. Wu et al., "Towards EMG-to-Speech with a Necklace Form Factor," in *Proc. Interspeech 2024*, Kos, Grecia, 2024, pp. 402-406.