

MYVOICE: Reconocimiento de comandos simples en dispositivos de voz asistida mediante señales EMG

Resumen: La pérdida de la capacidad de hablar debido a patologías laríngeas o procedimientos quirúrgicos representa una limitación significativa para la comunicación de los pacientes. En este contexto, las señales electromiográficas (EMG) constituyen una alternativa para detectar la intención de habla a partir de la actividad muscular residual involucrada en la articulación del lenguaje. El presente proyecto propone un sistema de reconocimiento de comandos basado en señales EMG adquiridas mediante un dispositivo BITalino y procesadas mediante técnicas de inteligencia artificial.

Las señales fueron obtenidas mediante electrodos de superficie colocados en músculos cervicales relacionados con la producción del habla, registrando los movimientos musculares asociados a la pronunciación silenciosa de comandos específicos. Posteriormente, los datos fueron preprocesados y utilizados para entrenar un modelo de clasificación en la plataforma Edge Impulse, empleando análisis espectral y aprendizaje automático para identificar patrones característicos de cada comando.

El sistema desarrollado permite clasificar la intención de pronunciación del usuario, constituyendo una prueba de concepto para futuras interfaces de comunicación asistida y sistemas de control de laringe electrónica. Los resultados obtenidos evidencian la viabilidad del uso de señales EMG superficiales para el reconocimiento de las comandos sí y no, ofreciendo una alternativa no invasiva para mejorar la comunicación de personas con alteraciones de la voz.

Palabras clave: electromiografía (EMG), reconocimiento de patrones, Edge Impulse, inteligencia artificial, BITalino.

Introducción

La pérdida de la capacidad de hablar como consecuencia de una laringectomía total o de otras patologías laríngeas representa una limitación significativa para la comunicación y la calidad de vida de los pacientes. Aunque la laringe electrónica constituye una de las principales alternativas para restaurar parcialmente la comunicación verbal mediante vibraciones mecánicas transmitidas al cuello, este dispositivo presenta limitaciones relacionadas con la naturalidad de la voz, la inteligibilidad del habla y la presencia de ruido mecánico durante su funcionamiento [1].

En este contexto, la electromiografía de superficie (sEMG) ha adquirido un papel relevante como una tecnología capaz de registrar la actividad eléctrica generada por los músculos implicados en la articulación del habla. El análisis de estas señales permite identificar la intención de pronunciación incluso en ausencia de sonido, dando origen a las denominadas interfaces de habla silenciosa (Silent Speech Interfaces, SSI). Sin embargo, las señales electromiográficas presentan una elevada susceptibilidad al ruido, a la fatiga muscular, al desplazamiento de los electrodos y a los artefactos producidos por el movimiento, lo que dificulta la discriminación de diferentes patrones musculares asociados al habla [1].

Con el propósito de abordar esta problemática, se desarrolló MYVOICE, un prototipo de software orientado al reconocimiento de comandos simples mediante señales electromiográficas de la musculatura cervical. El sistema fue diseñado para clasificar tres estados específicos: "SÍ", "NO" y "BASAL", empleando técnicas de procesamiento digital de señales e inteligencia artificial. Para ello, las señales adquiridas son preprocesadas, segmentadas en ventanas temporales, sometidas a extracción de características y posteriormente clasificadas mediante un modelo entrenado en la plataforma Edge Impulse [2].

El presente informe describe el desarrollo del sistema propuesto, incluyendo la adquisición de señales mediante BITalino, el procesamiento digital aplicado a los registros electromiográficos, el entrenamiento y validación del modelo de clasificación, así como la implementación de una interfaz de usuario para la ejecución de inferencias. Finalmente, se presentan los resultados obtenidos y se analizan las limitaciones actuales del prototipo como una prueba de concepto para futuras aplicaciones en dispositivos de asistencia a la comunicación basados en señales electromiográficas [3].

Planteamiento del problema

La pérdida parcial o total de la capacidad de hablar representa una limitación importante para la comunicación y la interacción social de los pacientes sometidos a una laringectomía total o afectados por trastornos severos de la fonación. Aunque la laringe electrónica constituye una de las principales alternativas para restaurar la comunicación oral, estos dispositivos presentan limitaciones relacionadas con la naturalidad de la voz generada, la presencia de ruido mecánico y la necesidad de un control manual durante su funcionamiento. Estas características reducen la inteligibilidad del habla y limitan la experiencia del usuario, evidenciando la necesidad de desarrollar soluciones de asistencia más intuitivas y personalizadas [4].

En los últimos años, la electromiografía de superficie (sEMG) ha surgido como una alternativa prometedora para el desarrollo de interfaces de habla silenciosa, ya que permite registrar la actividad eléctrica de los músculos implicados en la articulación del lenguaje incluso en ausencia de emisión sonora. No obstante, la adquisición e interpretación de estas señales continúa representando un desafío debido a su susceptibilidad al ruido, a los artefactos producidos por el movimiento, al desplazamiento de los electrodos y a la variabilidad fisiológica entre usuarios. Además, las diferencias entre los patrones musculares asociados a comandos cortos, como "SÍ" y "NO", son sutiles, por lo que resulta necesario aplicar técnicas de procesamiento digital de señales e inteligencia artificial que permitan mejorar su discriminación [5].

Si bien investigaciones recientes han demostrado el potencial de las interfaces de habla silenciosa basadas en señales electromiográficas, aún existe la necesidad de integrar en un mismo sistema las etapas de adquisición, procesamiento, clasificación y visualización de resultados mediante una interfaz accesible para el usuario. Asimismo, la mayoría de los estudios reportados corresponden a pruebas realizadas en sujetos sanos bajo condiciones controladas de laboratorio, por lo que todavía es necesario validar estas tecnologías en pacientes con alteraciones reales de la voz.

En este contexto, el proyecto MYOVOICE propone el desarrollo de un prototipo de software capaz de reconocer los comandos "SÍ", "NO" y el estado "BASAL" a partir de señales electromiográficas de la musculatura cervical. Para ello, se emplean técnicas de procesamiento digital de señales, extracción de características y aprendizaje automático con el propósito de evaluar la viabilidad de esta estrategia como una prueba de concepto para futuros sistemas de asistencia a la comunicación basados en electromiografía.

En consecuencia, la presente investigación busca responder la siguiente pregunta:

¿Cómo pueden aprovecharse las señales electromiográficas de la musculatura cervical para clasificar de manera confiable los comandos de habla silenciosa "SÍ", "NO" y el estado "BASAL" mediante un prototipo de software basado en inteligencia artificial?

Propuesta de solución

Como equipo de investigación, planteamos el diseño y desarrollo de un software prototipo de habla silenciosa orientado a diferenciar si un usuario está articulando el monosílabo “sí”, el monosílabo “no”, o si, por el contrario, se encuentra en un estado de reposo muscular sin emitir sonido (estado basal). Este proyecto tiene como meta a largo plazo ser utilizado como un sistema de asistencia comunicativa para dispositivos de voz (como laringes electrónicas) en pacientes que han sido sometidos a laringectomías totales o que padecen afecciones severas en las cuerdas vocales, permitiéndoles recuperar una comunicación verbal más fluida y natural.

Para lograr la adecuada clasificación de los comandos, se llevó a cabo la adquisición de señales de electromiografía de superficie (sEMG) mediante el uso del hardware MuscleBIT (BITalino) y el software de registro OpenSignals. La captura de datos tuvo como base una configuración de cinco electrodos: el electrodo 1 se posicionó en la clavícula izquierda como referencia, los electrodos 2 y 3 sirvieron para el registro de la actividad del músculo estilohioideo derecho e izquierdo y finalmente, los electrodos 4 y 5 se ubicaron sobre la sección anterior del músculo digástrico en sus lados derecho e izquierdo [6] - [9]. Todos los electrodos fueron colocados en el cuello y la mandíbula. Con ello, se procedió a muestrear las señales con una frecuencia de 1000 Hz.



Figura 1. Colocación de electrodos.

El procesamiento y la inferencia de los datos se estructuraron a través de un pipeline automatizado. Como paso inicial, los registros crudos obtenidos (.txt o .h5) se transformaron a un formato .json mediante scripts en Python. Posteriormente, la señal continua fue segmentada en ventanas temporales de 1000 muestras con duración de 1 segundo. A ellas se les aplicó una Transformada Rápida de Fourier de 64 puntos que permitió la extracción de características en tiempo y frecuencia.

Seguidamente, estos features pasaron por una etapa de normalización con un algoritmo StandardScaler para ser introducidos en una Red Neuronal Densa (DNN). Esta red fue previamente entrenada en el entorno de Edge Impulse y optimizada mediante una cuantización de enteros de 8 bits, lo que redujo drásticamente el uso de memoria a solo 3539 bytes de Tensor Arena. El pipeline concluye con una capa de post-procesamiento Softmax que entrega la clasificación final sujeta a un umbral de confianza mínimo configurable (60%) para mitigar la incertidumbre en el entorno real.

Resultados

Tras culminar el proceso de entrenamiento y validación del modelo de IA en Edge Impulse, se obtuvo un desempeño satisfactorio sobre el conjunto de validación. El sistema alcanzó una exactitud del 90.54% y un área bajo la curva ROC de 0.99. Asimismo, las métricas ponderadas de precisión y sensibilidad se situaron en un 0.93, acompañadas de un F1-score de 0.92. Adicionalmente, al evaluar el desempeño por clase mediante el F1-score, se observó un rendimiento de 0.99 para el estado basal, un 0.90 para la articulación del

comando "NO", y un 0.87 para el monosílabo "Sí". Los hallazgos demuestran que la clase de reposo es altamente distinguible y que los comandos emitidos cuentan con patrones diferenciables entre sí.




Figura 2. Precisión del algoritmo de IA.

Por otra parte, el despliegue tecnológico implicó la creación de una interfaz de usuario interactiva y modular desarrollada en Streamlit. Esta interfaz gráfica de usuario desarrollada en Streamlit interactúa de forma directa con el modelo de IA exportado desde Edge Impulse. El flujo de trabajo de la interfaz permite cargar data obtenida mediante BITalino o activar un generador de escenarios clínicos simulados para evaluar la robustez frente a cuatro perfiles de pacientes con diferentes condiciones (desde señales limpias hasta señales afectadas por ruido o fatiga muscular).

En lo que respecta a la data real, la aplicación cuenta con un módulo que admite archivos .txt o .csv exportados desde OpenSignals. Al importar el archivo de prueba, el sistema valida la integridad de los datos, confirma su lectura correcta y segmenta de forma automática la señal continua en ventanas. Las salidas se tabulan en una matriz que expone la predicción categórica final de cada ventana junto con su porcentaje global de confianza y el desglose probabilístico decimal exacto para las tres clases evaluadas.

INGRID_...CULADO.txt 210.0KB +					
✓ 5000 muestras, 4 canales					
✓ 9 ventanas clasificadas					
Ventana	Predicción	Confianza (%)	BASAL	NO	SI
1	SI	59.3	0.090	0.317	0.593
2	SI	67.9	0.127	0.194	0.679
3	SI	69.6	0.106	0.198	0.696
4	SI	88.5	0.006	0.109	0.885
5	SI	98.4	0.001	0.015	0.984
6	SI	67.7	0.029	0.293	0.677
7	SI	96.4	0.002	0.034	0.964
8	SI	76.9	0.012	0.219	0.769
9	SI	95.6	0.002	0.042	0.956

Figura 3. Prueba con datos reales de Sí.

Finalmente, la interfaz de usuario ofrece un sólido entorno visual para el análisis estadístico de los resultados. La plataforma genera un histograma titulado "Distribución de predicciones por ventana", el cual grafica la frecuencia con la que el modelo asignó cada clase, esto permite identificar visualmente los periodos de habla y reposo. Complementariamente, se implementó un panel de control en el extremo izquierdo que almacena el conteo acumulado de predicciones, proporcionando una herramienta metodológica útil para reportes de desempeño.




Figura 4. Distribución de predicciones de datos reales de BASAL.




Figura 5. Clasificación simulada

Conclusiones

MYOVOICE es un prototipo diseñado para el reconocimiento de comandos simples utilizando señales electromiográficas de superficie provenientes de la musculatura cervical. El prototipo desarrollado permitió clasificar los intentos de pronunciación de los comandos "SI", "NO" y una condición "BASAL", basándose en la actividad de los músculos suprahioides relacionados con la articulación del habla.

A través de esta interfaz, se facilita la interacción del usuario para simular señales, ejecutar procesos de inferencia y consultar el historial de predicciones. Para el análisis de datos reales, el sistema admite archivos en formato TXT o CSV provenientes de dispositivos BITalino, requiriendo que los registros contengan cuatro canales para poder procesarlos adecuadamente.

Dado que MYOVOICE se encuentra en una etapa inicial de desarrollo, su uso está orientado a fines académicos, experimentales y de investigación. Es importante considerar que la calidad de las predicciones depende directamente de la señal adquirida, la cual puede verse afectada por factores prácticos como el ruido, la mala colocación de los electrodos o la fatiga muscular. Por lo tanto, los resultados obtenidos son de carácter puramente experimental y no deben interpretarse como una evaluación clínica, ya que el sistema no sustituye a un dispositivo médico validado.

Referencias

- [1] J. T. Heaton, M. Robertson, and C. Griffin, "Development of a Wireless Electromyographically Controlled Electrolarynx Voice Prosthesis," *Proc. Annu. Int. Conf. IEEE Eng. Med. Biol. Soc. (EMBC)*, pp. 5352–5355, 2011, doi: 10.1109/IEMBS.2011.6091324.
- [2] J. Wu *et al.*, "A Novel Silent Speech Recognition Approach Based on Parallel Inception Convolutional Neural Network and Mel Frequency Spectral Coefficient," *Front. Neurobot.*, vol. 16, Art. no. 971446, 2022, doi: 10.3389/fnbot.2022.971446.
- [3] P. Wu *et al.*, "Towards EMG-to-Speech with Necklace Form Factor," in *Proc. Interspeech 2024*, Kos, Greece, 2024, pp. 402–406.
- [4] Z. Che *et al.*, "Speaking without Vocal Folds Using a Machine-Learning-Assisted

Wearable Sensing-Actuation System,” *Nat. Commun.*, vol. 15, no. 1, Art. no. 1952, 2024, doi: 10.1038/s41467-024-45915-7.

[5] M. Zhang, Y. Yuan, and S. Zhang, “Perspective Chapter: Silent Speech Interface Based on Neural Activity – A Short Review,” in *Human-Robot Interaction – A Multidisciplinary Overview*. London, U.K.: IntechOpen, 2025, doi: 10.5772/intechopen.1008554.

[6] I. Hwang, J. Lee, and K. Lee, “EMG-to-Speech with Fewer Channels,” *arXiv preprint*, arXiv:2602.06460, 2026. [Online]. Available: <https://arxiv.org/abs/2602.06460>

[7] I. Salomons, E. del Blanco, E. Navas, and I. Hernáez, “Electrode Setup for Electromyography-Based Silent Speech Interfaces: A Pilot Study,” *Sensors*, vol. 25, no. 3, Art. no. 781, 2025, doi: 10.3390/s25030781.

[8] F. Meier, G. Spacone, S. Frey, L. Benini, and A. Cossetini, “A Parallel Ultra-Low Power Silent Speech Interface Based on a Wearable, Fully-Dry EMG Neckband,” *arXiv preprint*, arXiv:2509.21964, 2025. [Online]. Available: <https://arxiv.org/abs/2509.21964>

[9] G. Spacone *et al.*, “SilentWear: An Ultra-Low Power Wearable System for EMG-Based Silent Speech Recognition,” *arXiv preprint*, arXiv:2603.02847, 2026. [Online]. Available: <https://arxiv.org/abs/2603.02847>